

Reconocimiento de golpes de bádminton mediante sensores inerciales y giroscopio: Estado del arte e investigación previa.

Marco Ruiz López, Universidad de Zaragoza

Abstract—El reconocimiento automático de golpes en bádminton mediante sensores inerciales (IMU) es un problema abierto dentro del campo del Reconocimiento de Actividad Humana aplicado al deporte. Este artículo presenta una revisión sistemática de literatura (SLR) siguiendo el protocolo PRISMA. La pregunta PICOS delimita el problema a sistemas basados en acelerómetro y giroscopio para clasificar golpes de bádminton, tomando como métricas de interés la exactitud de clasificación y la capacidad de generalización entre jugadores. De los 138 registros identificados en cuatro bases de datos, 13 publicaciones superaron el proceso de selección. Los resultados muestran que la IMU es el sensor principal en el campo, que los algoritmos de ML clásico —especialmente Random Forest y SVM— y las redes neuronales convolucionales ofrecen el mejor compromiso entre rendimiento y coste computacional, y que la generalización entre jugadores no vistos durante el entrenamiento es la limitación más crítica y menos resuelta. Ningún trabajo previo ha optimizado estos sistemas para su despliegue en hardware embebido de bajo coste, lo que representa una oportunidad directa para el trabajo experimental propuesto.

Index Terms—bádminton, reconocimiento de golpes, unidad de medida inercial, acelerómetro, giroscopio, aprendizaje automático, redes neuronales, revisión sistemática, PRISMA, deportes inteligentes.

I. INTRODUCCIÓN

EL bádminton es uno de los deportes de raqueta más practicados a nivel mundial. Su alta demanda técnica se refleja en la diversidad y velocidad de los golpes que lo componen. Clasificar automáticamente estos golpes a partir de señales de movimiento tiene aplicaciones directas en el análisis del rendimiento, la retroalimentación en tiempo real durante el entrenamiento, la cuantificación de carga de trabajo y el desarrollo de sistemas de entrenamiento asistido por tecnología.

El método tradicional para analizar el movimiento deportivo se basa en sistemas de captura óptica, que ofrecen alta precisión pero requieren entornos controlados y equipamiento costoso. Como alternativa, los sensores inerciales —acelerómetro y giroscopio integrados en una IMU— permiten capturar la cinemática del golpe de forma no intrusiva, a bajo coste y en condiciones reales de juego. Su tamaño reducido y bajo consumo energético los hacen idóneos para integrarlos en la raqueta o en el propio equipamiento del jugador.

La combinación de IMU con técnicas de aprendizaje automático (ML) ha generado una cantidad creciente de publicaciones en la última década. Sin embargo, el campo tiene problemas estructurales que dificultan sacar conclusiones claras: los datasets son pequeños y específicos de cada estudio, los

protocolos de validación son heterogéneos y, en la mayoría de los casos, los modelos no se evalúan frente a jugadores que no han participado en el entrenamiento. Esto compromete la validez de los resultados y dificulta elegir un algoritmo con base sólida para un sistema real.

El objetivo de este trabajo es identificar, mediante una revisión sistemática, qué sensores, algoritmos y estrategias de validación han demostrado ser eficaces para clasificar golpes de bádminton a partir de señales inerciales. Con ello se pretende: (1) caracterizar el estado actual del campo, (2) identificar las tendencias algorítmicas principales, (3) evaluar la calidad metodológica de los estudios publicados, y (4) delimitar la brecha de investigación que justifica el trabajo experimental propuesto.

El artículo se organiza del siguiente modo: la Sección II describe el protocolo SLR y la pregunta PICOS; la Sección III presenta los resultados del análisis; la Sección IV discute los hallazgos y delimita la brecha existente; y la Sección V recoge las conclusiones y el trabajo futuro.

II. METODOLOGÍA

La revisión sigue el protocolo de Revisión Sistemática de Literatura (SLR) conforme a las directrices PRISMA 2020 (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*).

A. Pregunta PICOS

La búsqueda y selección de estudios se guía por la siguiente pregunta estructurada según el marco PICOS:

P (Población/Plataforma): Jugadores de bádminton de cualquier nivel que ejecutan golpes con una raqueta instrumentada o con sensores sobre el cuerpo. El problema central es clasificar automáticamente el tipo de golpe (smash, clear, drop, drive, net, serve u otras categorías) a partir de señales de movimiento.

I (Intervención): Uso de acelerómetro y/o giroscopio (IMU) como sensor principal, procesados mediante algoritmos de ML supervisado, deep learning, o métodos de extracción de características sobre señal inercial.

C (Comparación): Comparación interna entre algoritmos sobre el mismo dataset, o comparación con soluciones comerciales como USENSE o CoolLang.

O (Outcomes): Métrica principal: exactitud (accuracy) en la clasificación del tipo de golpe. Métricas secundarias: F1-score

por clase, recall y capacidad de generalización entre jugadores no vistos durante el entrenamiento.

S (Tipos de estudio): Artículos de revista indexada, actas de congreso con revisión por pares y tesis. Se admiten estudios desde 2015 en adelante para ML sobre IMU. Se excluyen trabajos basados únicamente en visión por computador, EMG o sensores no inerciales.

B. Bases de datos y cadenas de búsqueda

La búsqueda se realizó en cuatro bases de datos: IEEE Xplore, Scopus, Web of Science y Google Scholar. Se utilizaron cadenas de búsqueda booleanas con dos grupos temáticos: el primero orientado a la clasificación de golpes en bádminton con IMU, y el segundo extendido al reconocimiento de actividad humana en deportes de raqueta. Un ejemplo representativo de cadena de búsqueda es el siguiente:

```
("badminton" OR "racket sport")
AND ("IMU" OR "accelerometer" OR
"gyroscope" OR "inertial sensor")
AND ("stroke recognition" OR
"stroke classification" OR "action
recognition") AND ("machine learning"
OR "deep learning" OR "SVM" OR "random
forest" OR "CNN" OR "LSTM")
```

C. Criterios de inclusión y exclusión

Se incluyeron los trabajos que cumplen simultáneamente los siguientes criterios:

- (I1) El estudio trabaja con golpes de bádminton o movimientos de raqueta como objeto de clasificación.
- (I2) El sistema emplea al menos un acelerómetro o giroscopio como fuente primaria de datos.
- (I3) El procesamiento incluye ML supervisado, deep learning o extracción de características sobre señal inercial.
- (I4) Los resultados se validan con datos reales capturados con sujetos ejecutando golpes.
- (I5) El estudio reporta al menos una métrica cuantitativa de clasificación (accuracy, F1, recall o matriz de confusión).

Se excluyeron los trabajos que incurren en alguno de los siguientes criterios:

- (WF) El deporte no es bádminton, o el sensor principal es cámara, EMG, EEG, ECG o lidar sin componente IMU.
- (NR-1) El objetivo no es clasificar golpes, sino estimar carga o analizar biomecánica descriptiva sin ML.
- (SER) El documento es una revisión o survey, no un estudio primario.
- (LR-4) El texto completo no está disponible en acceso libre.

D. Flujo de selección PRISMA

La Fig. 1 muestra el diagrama de flujo PRISMA. A partir de los 161 registros identificados, se eliminaron los duplicados, quedando 138 registros únicos, y se realizó el cribado por título y resumen. De los 138 registros únicos, 124 fueron excluidos mediante los criterios WF, NR-1, SER y LR-4. Los 14 restantes




Fig. 1. Diagrama de flujo PRISMA del proceso de selección de estudios.

pasaron a la fase de elegibilidad por texto completo, donde se descartó 1 adicional por criterios de calidad. Finalmente, 13 publicaciones superaron todos los criterios y se incorporaron a la síntesis cualitativa.

III. RESULTADOS

El proceso de selección dio como resultado 13 publicaciones para la síntesis cualitativa, que abarcan el período 2015–2025. A continuación se analizan los sensores empleados, los enfoques algorítmicos y las estrategias de validación identificados.

A. Sensores y configuraciones hardware

La IMU, compuesta por acelerómetro y giroscopio triaxiales, es el sensor principal en la práctica totalidad de los trabajos incluidos. La posición de montaje varía entre estudios: la raqueta o su mango es la ubicación más frecuente [1], [2], [4], [7], seguida de la muñeca dominante [5], [9], [11] y combinaciones de múltiples nodos corporales [9], [11], [12].

El número de nodos es un factor de diseño relevante. Zhang et al. [9] analizan la influencia de la posición y el número de sensores, y concluyen que un único sensor en la muñeca derecha con SVM alcanza un 95% de accuracy, muy próximo al 98% obtenido con cinco sensores. Esto indica que añadir más nodos no siempre compensa la complejidad añadida.

Algunos trabajos combinan la IMU con modalidades adicionales. Lin et al. [6], [13] añaden un micrófono Bluetooth en la raqueta para detectar el impacto del volante mediante análisis de voiceprint, logrando una tasa de detección cercana

TABLE I
SENSORES Y CONFIGURACIONES HARDWARE EN LOS TRABAJOS
REVISADOS

Ref.	Sensores principales	Posición	Frec. (Hz)
[1]	Aceleróm. + Gyro (MPU-6050)	Raqueta	N/D
[2]	IMU MEMS	Base raqueta	50
[3]	IMU MPU-9150 ×4 + FSR	Cuerpo + raqueta	200
[4]	Aceleróm. + Gyro (AX6)	Raqueta	50
[5]	IMU Physilog 4 ×2	Pecho + muñeca	100
[6]	IMU Koala + Micrófono BLE	Raqueta	N/D
[7]	MEMS flexible ×3	Mango raqueta	100
[8]	Aceleróm. + actitud	Raqueta	200
[9]	IMU ×6	Cuerpo + raqueta	50
[10]	IMU Opal ×2	Miembro sup. + raqueta	N/D
	IMU ×2 + ECG + EEG	Muñeca + raqueta	50/512
[11]	IMU ×4 (ZigBee)	Cuerpo (4 nodos)	100
[12]	IMU Koala + Micrófono BLE	Raqueta	N/D
[13]			

al 100%. Qin et al. [11] fusionan IMU con ECG y EEG, observando que estas señales fisiológicas aportan poco de forma individual y que la combinación óptima es la IMU de muñeca más la de la raqueta. Kurnia et al. [3] añaden sensores de fuerza resistivos (FSR) en el mango. La Tabla I recoge los sensores y configuraciones de todos los trabajos incluidos.

B. Enfoques algorítmicos

1) *Análisis biomecánico sin clasificación ML*: Dos trabajos de los estudios incluidos no realizan clasificación automática de golpes, sino que adoptan un enfoque descriptivo o estadístico. Kurnia et al. [3] utilizan la correlación de Pearson para medir la similitud entre los patrones de movimiento de atletas y un entrenador de referencia en smash y dropshot. Los atletas obtienen similitudes superiores al 50%, mientras que los participantes no entrenados se quedan por debajo de ese umbral. Shan et al. [10] realizan un análisis biomecánico del smash con sensores Opal APDM, identificando que la muñeca es la articulación que más contribuye al movimiento y que su sincronización con la raqueta es la más alta de todos los segmentos analizados. Ambos trabajos aportan contexto sobre la cinemática del golpe, pero no proporcionan métricas de clasificación comparables con el resto de los estudios incluidos.

2) *Machine learning clásico*: El ML clásico supervisado es el enfoque más frecuente en los estudios incluidos. Anik et al. [1] aplican SVM y k-NN sobre características de señal IMU (MPU-6050) para clasificar tres tipos de golpe, obteniendo un 88.89% de accuracy con SVM frente a un 58% con k-NN. Es el trabajo más temprano de los estudios incluidos y sirve como referencia histórica del problema.

Zhang et al. [2] proponen un sistema de reconocimiento online de seis golpes que incorpora una clasificación previa

del modo de agarre (*grip*). Con Random Forest alcanzan un 95.36% de accuracy, superando claramente a Naïve Bayes (78.2%) y k-NN (90.4%). Ghazali et al. [5] comparan nueve variantes de SVM, k-NN y árbol de decisión sobre 15 clases de golpe con dos sensores Physilog 4, reportando un 83.4% con SVM Cubic y un 39% de falsos negativos en el smash debido a su alta variabilidad intra-clase.

Los trabajos de Lin et al. [6], [13] proponen una raqueta inteligente que combina IMU con micrófono Bluetooth, separando la detección del evento (voiceprint, $F=0.999$) de la clasificación del golpe (SMO Poly, 96.5% en modelo personal; 84% en modelo general). La diferencia de más de 12 puntos entre el modelo personal y el general es la limitación principal de estos trabajos, y es un patrón que se repite en todos los estudios incluidos.

Zhang et al. [9] comparan todas las combinaciones posibles de 1 a 5 sensores en distintas posiciones corporales. El resultado principal es que SVM con un único sensor en la muñeca derecha (95%) es casi equivalente a cinco sensores (98%), con un coste mucho menor.

3) *Deep learning y modelos secuenciales*: Los métodos de deep learning y modelado secuencial son los que obtienen las métricas más altas de los estudios incluidos, aunque también los que presentan mayor riesgo de sesgo metodológico.

Peralta et al. [4] entrenan una CNN con capas Conv2D sobre datos del sensor Axivity AX6, usando data augmentation y transfer learning para mejorar la generalización entre jugadores. El modelo individual alcanza el 95.91% de accuracy, mientras que el modelo generalizado cae al 93% cuando se usa solo el acelerómetro, ya que añadir el giroscopio empeora la generalización por sobreajuste. Este es el único trabajo de los estudios incluidos con calidad alta (6/8) según la evaluación Cochrane adaptada.

Wang et al. [8] proponen una arquitectura de clasificación jerárquica (HMC) con un clasificador de nivel superior y clasificadores específicos por subcategoría, sobre MobileNetV2, ResNet50 y ResNet101. El sistema alcanza un 83.9% de accuracy sobre el dataset BSS-V2 de 37 actividades, mejorando en 1.7 puntos al baseline AFEB-MobileNet y en 15.5 puntos al LSTM.

Liu y Wu [12] aplican Hidden Markov Model (HMM) con *wavelet denoising* y LDA sobre cuatro nodos IMU, clasificando 14 tipos de golpe con un 98.13% de accuracy sobre el dataset más grande de los estudios incluidos (50 sujetos, 50 repeticiones por clase). La fusión acelerómetro+giroscopio mejora en más de seis puntos el uso de cada modalidad por separado.

Li et al. [7] proponen una CNN 1D con sensores MEMS flexibles en el mango de la raqueta, reportando un 99% de accuracy en 10 clases. Sin embargo, este trabajo presenta la calidad metodológica más baja de los estudios incluidos (1.5/8): no declara el número de sujetos, no especifica el tamaño del dataset, no compara con ningún baseline y no reporta limitaciones. Por este motivo, sus resultados no son verificables y no deben usarse como referencia.

Qin et al. [11] comparan AlexNet y GoogLeNet con fusión de IMU, ECG y EEG sobre seis voluntarios. La combinación óptima, muñeca derecha más raqueta con AlexNet, alcanza un

92.9% de accuracy. Curiosamente, usar los cuatro sensores a la vez baja al 68.4%, lo que indica un efecto de redundancia de información perjudicial.

C. Validación experimental y métricas

La estrategia de validación más usada en los estudios incluidos es la validación cruzada k-fold sobre el dataset completo, sin separar sujetos entre entrenamiento y test [1], [5], [6], [8], [9], [11], [13]. Esta estrategia sobreestima el rendimiento real frente a jugadores nuevos, ya que el modelo puede aprender características propias de cada sujeto durante el entrenamiento.

Solo dos trabajos separan explícitamente los sujetos entre entrenamiento y test. Zhang et al. [2] reservan 3 sujetos para test (de 12 en total). Peralta et al. [4] evalúan tanto el modelo individual (entrenado y testado sobre el mismo jugador) como el modelo generalizado (entrenado sobre 4 jugadores, testado sobre el quinto). Esta última aproximación es la más rigurosa de los estudios incluidos.

La accuracy global es la métrica más reportada, apareciendo en todos los trabajos excepto en Kurnia et al. [3] y Shan et al. [10], que no realizan clasificación. Los trabajos más rigurosos añaden F1-score por clase [4], [13] y matrices de confusión completas [5], [9], [11], [12]. Ningún trabajo reporta la tasa de falsos positivos como métrica principal.

La Tabla II recoge la síntesis comparativa de los 13 trabajos incluidos.

IV. DISCUSIÓN

A. Tendencias identificadas

Del análisis de los trabajos revisados se identifican cuatro tendencias principales en el campo.

En primer lugar, se observa una evolución desde el ML clásico hacia el deep learning conforme aumenta la disponibilidad de datos. Los trabajos más tempranos [1], [6] usan SVM y Random Forest sobre ventanas deslizantes con características estadísticas. Los más recientes incorporan CNN [4], [7], arquitecturas jerárquicas [8] y fusión de modalidades con deep learning [11]. Sin embargo, el deep learning no muestra una ventaja sistemática sobre el ML clásico: Liu y Wu [12], con HMM, alcanzan el 98.13% sobre el dataset más grande del corpus, superando en accuracy a varias CNN que trabajan con datasets mucho menores.

En segundo lugar, la señal inercial se consolida como el núcleo del sistema. La presencia de la IMU en todos los trabajos indica que contiene información suficiente para resolver el problema, y que los sensores adicionales (micrófono, ECG, EEG, FSR) actúan como complemento, no como sustituto. El resultado de Zhang et al. [9], que muestra que un único sensor en la muñeca con SVM es casi equivalente a cinco sensores corporales, refuerza esta conclusión.

En tercer lugar, la brecha entre el modelo personal y el modelo general es un patrón recurrente. Cuatro trabajos evalúan explícitamente esta distinción [2], [4], [6], [13], y en todos ellos el modelo general cae entre 3 y 16 puntos respecto al personal. Esta brecha no se ha resuelto en ninguno de los

trabajos revisados y es el principal obstáculo para desplegar un sistema real con usuarios nuevos.

Por último, la eficiencia computacional no aparece como criterio de diseño en ninguno de los trabajos revisados. Ninguno reporta métricas de latencia, consumo energético ni tamaño del modelo, lo que indica que el campo no ha orientado su producción hacia el despliegue en hardware embebido de bajo coste.

B. Limitaciones comunes en la literatura

Para evaluar la calidad metodológica de los 13 trabajos incluidos se ha utilizado una checklist adaptada del método Cochrane, compuesta por 8 ítems. Cada ítem se puntúa como Sí (1 punto), Parcial (0.5 puntos) o No (0 puntos), con una puntuación máxima de 8. Se considera calidad alta una puntuación ≥ 6 , calidad media entre 4 y 5.5, y calidad baja por debajo de 4. Los ítems evaluados son los siguientes:

- **I1 — Validación real:** ¿Se valida el sistema con datos reales y no solo con simulación?
- **I2 — Tamaño de muestra:** ¿El tamaño del dataset es suficiente para las conclusiones (≥ 10 sujetos o ≥ 500 eventos)?
- **I3 — Métricas estándar:** ¿Las métricas de evaluación están claramente definidas y son estándar (accuracy, F1, recall)?
- **I4 — Comparador o baseline:** ¿Se compara el sistema con al menos un método de referencia?
- **I5 — Reproducibilidad:** ¿El código o protocolo experimental es reproducible (datos o código público)?
- **I6 — Limitaciones declaradas:** ¿Se documentan explícitamente las limitaciones del sistema?
- **I7 — Generalización:** ¿Los resultados son generalizables a diferentes sujetos o entornos?
- **I8 — Conflicto de interés:** ¿Se declaran conflictos de interés o fuentes de financiación?

Se identifican cuatro limitaciones recurrentes que afectan a la solidez de los resultados.

La primera y más importante es la falta de generalización entre sujetos en la validación. El ítem I7 de la evaluación de calidad Cochrane adaptada muestra que ningún trabajo de los estudios incluidos obtiene un «Sí» en este criterio (0% «Sí», 31% «Parcial»). La estrategia más común, la validación cruzada k-fold sin separar sujetos, sobreestima el rendimiento real con jugadores nuevos, que es precisamente el escenario de uso práctico.

La segunda limitación es el tamaño reducido de los datasets. La mayoría de estudios trabajan con menos de 15 sujetos y no declaran el número total de instancias con precisión. Solo Liu y Wu [12] superan este umbral claramente, con 50 sujetos y 50 repeticiones por clase. La falta de repositorios públicos impide comparar trabajos directamente y reproducir resultados.

La tercera limitación es la baja reproducibilidad. El ítem I5 obtiene un 0% de «Sí» y un 85% de «Parcial»: ningún trabajo publica el código ni el dataset. Algunos trabajos describen los parámetros del modelo con suficiente detalle [2], [4], pero reproducirlos requeriría acceso a los datos originales.

TABLE II
TABLA COMPARATIVA DE LOS TRABAJOS INCLUIDOS EN LA REVISIÓN (ORDEN CRONOLÓGICO)

Ref.	Año	Plataforma / sensor	Algoritmo	Validación	Resultado principal	N suj.	Cal.
[10]	2015	Opal APDM ×2 (miembro sup. + raqueta)	Biomecánico desc. — sin ML	Lab. controlado	Sin accuracy de clasificación. Muñeca: articulación de mayor contribución al smash	10	3.5
[1]	2016	MPU-6050 (raqueta)	SVM (Weka), k-NN	Hold-out 80/20	Acc. 88.89% (SVM, 3 cl.); ≈58% (k-NN)	N/D	2.5
[6]	2017	IMU Koala + mic. BLE (raqueta)	RF, SMO-Poly, NB + voiceprint	10-fold CV	Acc. 95.91% personal / 79.32% general (6 cl.); detección: F=0.999	10	4.5
[3]	2020	MPU-9150 ×4 + FSR (cuerpo + raqueta)	Correlación Pearson — sin ML	Comparación grupal	Sin accuracy. Similitud >50% atletas; <50% no entrenados	12	1.5
[8]	2020	Sensor prop. 200 Hz (raqueta)	HMC-MobileNetV2 (CNN jerárq.)	5-fold CV (80/20)	Acc. 83.9% (HMC-MobileNet, 37 cl.); LSTM baseline: 68.4%	N/D	4.0
[13]	2020	IMU Koala + mic. BLE (raqueta)	SMO-Poly, RF, NB + voiceprint	10-fold CV	Acc. 96.5% personal / 84% general (6 cl.); mejora +2–3× vs. IMU sola	10	5.5
[12]	2021	Acc.+Gyro ×4 Zig-Bee (4 nodos cuerpo)	HMM + wavelet de-noising + LDA	75/25, ×3 rep.	Acc. 98.13% (acc+gyro, 14 cl.); 91.99% (solo acc.); 91.60% (solo gyro)	50	5.0
[4]	2022	Axivity (raqueta)	AX6 CNN-2D + data aug. + TL	LOSO (5 jugadores)	Acc. 95.91% individual; 93% con solo aceleróm. [†] en modo generalizado (7 cl.)	5	6.0
[5]	2022	Physilog 4 ×2 (pecho + muñeca)	SVM, k-NN, DT (9 variantes)	10-fold CV	Acc. 83.4% (SVM Cubic, 15 cl.); FNR smash: 39%	10	4.0
[2]	2023	IMU MEMS (base raqueta)	RF, NB, LR, KNN, C4.5	9 suj. train / 3 suj. test	Acc. 95.36% (RF, 6 cl.); KNN: 90.4%; NB: 78.2%	12	3.5
[9]	2023	Acc.+Gyro ×6 (5 cuerpo + raqueta)	KNN (k=3), SVM, C4.5	10-fold CV	Acc. 98% (5 sens., SVM) / 95% (1 muñeca, SVM); 9 cl.	4	4.0
[11]	2023	IMU ×2 + ECG + EEG (muñeca + raqueta)	AlexNet, GoogLeNet (fusión pond.)	9/10 val. cruzada	Acc. 92.9% (muñeca+raqueta, AlexNet); 68.4% con 4 sens. (efecto redundancia)	6	4.0
[7]	2025	MEMS flex. ×3 (mango raqueta)	1D-CNN (3 capas conv.)	Sin especificar; sin baseline	Acc. 99% (10 cl.) — sin n° sujetos declarado; resultado no verificable	N/D	1.5

[†]El 93% en [4] es el modelo entrenado *solo con acelerómetro* en modo generalizado; añadir el giroscopio empeora la generalización por sobreajuste. *Cursiva*: trabajos sin clasificador ML, sin accuracy comparable. **Negrita** en Cal.: único trabajo de calidad alta (≥6/8). DT: árbol de decisión; TL: transfer learning; HMC: hierarchical multi-classification; LOSO: leave-one-subject-out; RF: Random Forest; NB: Naïve Bayes; SMO: Sequential Minimal Optimization (SVM); HMM: Hidden Markov Model; N/D: no declarado; cl.: clases; Cal.: calidad Cochrane /8.

La cuarta limitación afecta a los estudios con bajo rigor metodológico (P01, P03, P07, P10). Li et al. [7] reportan un 99% de accuracy sin declarar el número de sujetos ni el protocolo de validación, por lo que ese resultado no es interpretable. Kurnia et al. [3] no usan métricas estándar de clasificación, por lo que sus resultados no son comparables con el resto de los estudios incluidos.

C. Brecha de investigación

Ninguno de los trabajos revisados aborda el reconocimiento de golpes de bádminton con IMU orientado al despliegue en hardware embebido de bajo coste. Esta brecha tiene dos dimensiones.

Desde el punto de vista algorítmico, los estudios incluidos permite identificar los mejores candidatos: Random Forest [2] y SVM [9] ofrecen el mejor compromiso entre accuracy y simplicidad computacional entre los métodos clásicos. Entre los métodos de deep learning, las CNN 1D y las arquitecturas ligeras como MobileNetV2 [8] son las más viables

para dispositivos con restricciones de memoria y latencia. Sin embargo, ninguno de estos modelos se ha optimizado ni evaluado para su ejecución en microcontroladores de gama baja.

Desde el punto de vista de los datos, la ausencia de un dataset público con protocolo leave-one-subject-out obliga a construir uno propio en cualquier trabajo experimental futuro. El diseño de ese dataset —número de sujetos, tipos de golpe, protocolo de etiquetado, frecuencia de muestreo y posición del sensor— es en sí mismo una contribución de investigación.

V. CONCLUSIONES

Este artículo ha revisado sistemáticamente 13 publicaciones sobre reconocimiento de golpes de bádminton mediante sensores inerciales, seleccionadas de entre 138 registros mediante el protocolo PRISMA 2020. La pregunta PICOS delimitó el alcance a sistemas basados en IMU para la clasificación de golpes, tomando como métricas principales la accuracy de clasificación y la generalización entre sujetos.

Del análisis se extraen tres conclusiones principales. En primer lugar, la IMU es el sensor suficiente y dominante: un único sensor bien posicionado (muñeca o mango de raqueta) permite alcanzar niveles de accuracy competitivos con configuraciones multimodales más complejas. En segundo lugar, Random Forest y SVM son los clasificadores con mejor compromiso rendimiento-eficiencia entre los métodos clásicos; para deep learning, las CNN 1D y las arquitecturas MobileNet son el candidato más prometedor en plataformas con recursos limitados. En tercer lugar, la generalización entre jugadores no vistos durante el entrenamiento es la limitación más importante del campo y la menos resuelta: ningún trabajo de los estudios incluidos aborda este problema de forma sistemática.

Como trabajo futuro se plantean tres líneas. Primero, diseñar y construir un dataset de golpes de bádminton, capturado con una IMU de bajo coste en el mango de la raqueta o la muñeca del jugador. Segundo, con ese dataset, evaluar y comparar diferentes modelos de ML clásico y deep learning, optimizando los modelos para ejecutarse en un microcontrolador de bajo coste. Tercero, caracterizar cómo el nivel de habilidad del jugador afecta al rendimiento del clasificador, como variable de generalización no abordada en los estudios incluidos.

AGRADECIMIENTOS

El autor ha utilizado herramientas de inteligencia artificial (Claude, ChatGPT, Gemini, NotebookLM, Consensus, Rayyan, Elicit) como asistentes en las fases de búsqueda bibliográfica, extracción de datos y revisión del texto. Todo el contenido ha sido verificado, reescrito y validado por el autor, quien asume plena responsabilidad sobre la exactitud y originalidad del trabajo.

REFERENCES

- [1] M. A. I. Anik *et al.*, “Activity Recognition of a Badminton Game Through Accelerometer and Gyroscope,” in *Proc. 19th Int. Conf. Comput. Inf. Technol. (ICCIT)*, Dhaka, Bangladesh, Dec. 2016, pp. 213–217.
- [2] Y. Zhang *et al.*, “An Online Recognition Method of Badminton Stroke Based on Inertial Sensor,” in *Proc. 3rd Int. Conf. Comput. Control Robot. (ICCCR)*, 2023, pp. 75–81.
- [3] R. Kurnia, A. Pasmai, and I. Elfriti, “Analysis of the Smash and Dropshot Movement Patterns in Badminton Sports using Pearson Correlation,” in *Proc. ACM ICBET 2020*, Tokyo, 2020, pp. 164–169, doi: 10.1145/3397391.3397434.
- [4] D. Peralta *et al.*, “Badminton stroke classification based on accelerometer data: from individual to generalized models,” in *Proc. IEEE Int. Conf. Big Data*, 2022, pp. 5542–5548.
- [5] N. F. Ghazali, N. Shahar, and M. A. As’ari, “Badminton Strokes Recognition using Inertial Sensor and Machine Learning Approach,” in *Proc. 2nd ICICyTA*, 2022, pp. 1–5.
- [6] J. Lin *et al.*, “Design and Implement a Mobile Badminton Stroke Classification System,” in *Proc. APNOMS*, 2017, pp. 235–238.
- [7] J. Li, J. Gong, and Y. Zhao, “Flexible Electronic Sensing Systems for Motion Recognition in Sports Training: A Badminton Application,” in *Proc. 4th IEEE NSENS*, 2025, pp. 41–45, doi: 10.1109/NSENS65807.2025.11427970.
- [8] Y. Wang *et al.*, “Hierarchical Multi-Classification for Sensor-based Badminton Activity Recognition,” in *Proc. 15th IEEE Int. Conf. Signal Process. (ICSP)*, 2020, pp. 371–375, doi: 10.1109/ICSP48669.2020.9320935.
- [9] X. Zhang *et al.*, “Inertial Sensor Binding Position and Combination in Badminton Action Recognition Using Machine Learning,” in *Proc. 13th IEEE CYBER*, 2023, pp. 285–290, doi: 10.1109/CYBER59472.2023.10256491.

- [10] C. Z. Shan *et al.*, “Investigation of Upper Limb Movement during Badminton Smash,” in *Proc. 10th Asian Control Conf. (ASCC)*, 2015, pp. 1–6.
- [11] L. Qin *et al.*, “Optimizing Badminton Action Recognition with Deep Learning and Sensor Fusion: A Study of Sensor Numbers and Combinations,” in *Proc. 13th IEEE CYBER*, 2023, pp. 273–278, doi: 10.1109/CYBER59472.2023.10256460.
- [12] J. Liu and X. Wu, “Research on Badminton Motion Recognition Based on Hidden Markov Model,” in *Proc. 2021 Int. Conf. Netw. Syst. AI (INSAI)*, 2021, pp. 11–16, doi: 10.1109/INSAI54028.2021.00014.
- [13] J. Lin *et al.*, “Sensor-based Badminton Stroke Classification by Machine Learning Methods,” in *Proc. ICPAI*, 2020, pp. 94–100.